



## Answer of PR.2014.final

李田所

lium15@njnu.edu.cn

December 28, 2021



## Answer

### 1. 名词解释. 10 分

略。

### 2. K-L transform. 10 分

解法一（用 Fisher 判别分析，计算较简单）

已知两类情况下，K-L 变换求出的最优坐标轴方向就是就是 Fisher 线性判别中得到的最佳投影方向（课本 219 页）。

用 Fisher 线性判别解过程如下。

首先根据题目信息求均值向量

$$\mathbf{m}_1 = [0.75, 0.25, 0.75]^T \quad (1)$$

$$\mathbf{m}_2 = [0.25, 0.75, 0.25]^T \quad (2)$$

再分别计算两个类的类内离散度矩阵

$$\mathbf{S}_1 = \sum_{x_j \in \omega_1} (\mathbf{x}_j - \mathbf{m}_1)(\mathbf{x}_j - \mathbf{m}_1)^T = \begin{bmatrix} 0.75 & 0.25 & -0.25 \\ 0.25 & 0.75 & 0.25 \\ -0.25 & 0.25 & 0.75 \end{bmatrix} \quad (3)$$

$$\mathbf{S}_2 = \sum_{x_j \in \omega_2} (\mathbf{x}_j - \mathbf{m}_2)(\mathbf{x}_j - \mathbf{m}_2)^T = \begin{bmatrix} 0.75 & 0.25 & -0.25 \\ 0.25 & 0.75 & 0.25 \\ -0.25 & 0.25 & 0.75 \end{bmatrix} \quad (4)$$

总类内离散度矩阵为

$$\mathbf{S}_w = \mathbf{S}_1 + \mathbf{S}_2 = \begin{bmatrix} 1.5 & 0.5 & -0.5 \\ 0.5 & 1.5 & 0.5 \\ -0.5 & 0.5 & 1.5 \end{bmatrix} \quad (5)$$

则最优投影方向为

$$\begin{aligned} \mathbf{w}_1^* &= \mathbf{S}_w^{-1}(\mathbf{m}_1 - \mathbf{m}_2) = \begin{bmatrix} 1 & -0.5 & 0.5 \\ -0.5 & 1 & -0.5 \\ 0.5 & -0.5 & 1 \end{bmatrix} \begin{bmatrix} 0.5 \\ -0.5 \\ 0.5 \end{bmatrix} \\ &= \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix} \end{aligned} \quad (6)$$

即求得最优投影方向为  $[1, -1, 1]^T$ 。

解法二（K-L transform，过程较繁琐）

K-L transform 中的总类内离散度矩阵  $\mathbf{S}_w$  和类间离散度矩阵  $\mathbf{S}_b$  与 Fisher 线性判别分析中有些微不同。我们先根据题目信息求解如下。

首先根据题目信息求均值向量

$$\boldsymbol{\mu}_1 = [0.75, 0.25, 0.75]^T \quad (7)$$

$$\boldsymbol{\mu}_2 = [0.25, 0.75, 0.25]^T \quad (8)$$

$$\boldsymbol{\mu} = \frac{1}{2}(\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2) \quad (9)$$

$$= [0.5, 0.5, 0.5]^T \quad (10)$$

之后求总类内离散度矩阵

$$\mathbf{S}_w = \sum_{x_j \in \omega_1} (\mathbf{x}_j - \boldsymbol{\mu}_1)(\mathbf{x}_j - \boldsymbol{\mu}_1)^T + \sum_{x_j \in \omega_2} (\mathbf{x}_j - \boldsymbol{\mu}_2)(\mathbf{x}_j - \boldsymbol{\mu}_2)^T = \begin{bmatrix} 0.75 & 0.25 & -0.25 \\ 0.25 & 0.75 & 0.25 \\ -0.25 & 0.25 & 0.75 \end{bmatrix} \quad (11)$$

类间离散度矩阵为

$$\mathbf{S}_b = \frac{1}{2}(\boldsymbol{\mu}_1 - \boldsymbol{\mu})(\boldsymbol{\mu}_1 - \boldsymbol{\mu})^T + \frac{1}{2}(\boldsymbol{\mu}_2 - \boldsymbol{\mu})(\boldsymbol{\mu}_2 - \boldsymbol{\mu})^T = \begin{bmatrix} 0.0625 & -0.0625 & 0.0625 \\ -0.0625 & 0.0625 & -0.0625 \\ 0.0625 & -0.0625 & 0.0625 \end{bmatrix} \quad (12)$$

对总类内离散度矩阵  $\mathbf{S}_w$  做特征分解并对特征向量阵做 Gram-Schmidt 正交化，即

$$\mathbf{U}^T \mathbf{S}_w \mathbf{U} = \boldsymbol{\Lambda} \quad (13)$$

其中，求解得

$$\mathbf{U} = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{3}} & \frac{1}{\sqrt{6}} \\ 0 & \frac{1}{\sqrt{3}} & \frac{2}{\sqrt{6}} \end{bmatrix} \quad (14)$$

$$\boldsymbol{\Lambda} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0.25 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad (15)$$

令

$$\mathbf{B} = \mathbf{U} \boldsymbol{\Lambda}^{-\frac{1}{2}} = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{3}} & \frac{1}{\sqrt{6}} \\ 0 & \frac{1}{\sqrt{3}} & \frac{2}{\sqrt{6}} \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{2}{\sqrt{3}} & -\frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{2}} & -\frac{2}{\sqrt{3}} & \frac{1}{\sqrt{6}} \\ 0 & \frac{2}{\sqrt{3}} & \frac{2}{\sqrt{6}} \end{bmatrix} \quad (16)$$

对类间离散度矩阵进行变换成为

$$\mathbf{S}'_b = \mathbf{B}^T \mathbf{S}_b \mathbf{B} = \frac{1}{16} \begin{bmatrix} 0 & 0 & 0 \\ \sqrt{2} & -\sqrt{2} & \sqrt{2} \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \sqrt{3} & 2\sqrt{2} & -1 \\ \sqrt{3} & -2\sqrt{2} & 1 \\ 0 & 2\sqrt{2} & 2 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0.75 & 0 \\ 0 & 0 & 0 \end{bmatrix} \quad (17)$$

显然  $\mathbf{S}'_b$  相似于对角阵即自身，求解其对应于非零特征值 0.75 的特征向量

$$\mathbf{v} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \quad (18)$$

最佳方向为

$$\mathbf{w}_2^* = \mathbf{B}\mathbf{v} = \frac{1}{\sqrt{6}} \begin{bmatrix} 2\sqrt{2} \\ -2\sqrt{2} \\ 2\sqrt{2} \end{bmatrix} \quad (19)$$

和解法一中 Fisher 判别分析得到的最优投影方向  $[1, -1, 1]^T$  一致。

### 3. Perceptron/MSE. 20 分

(1) 用感知器算法求判别函数。

样本的增广化规范向量为

$$\begin{aligned} \mathbf{y}_1 &= [1, 1, 1]^T, & \mathbf{y}_2 &= [1, 1, 2]^T, & \mathbf{y}_3 &= [1, 2, 1]^T \\ \mathbf{y}_4 &= [-1, 0, 1]^T, & \mathbf{y}_5 &= [-1, 1, -1]^T, & \mathbf{y}_6 &= [-1, 2, 1]^T \end{aligned}$$

| iteration | feature vector  | $g(\mathbf{y}_i)$ | weight vector  |
|-----------|-----------------|-------------------|----------------|
| 1         | $[1, 1, 1]^T$   | $= 0$             | $[1, 1, 1]^T$  |
|           | $[1, 1, 2]^T$   | $> 0$             |                |
|           | $[1, 2, 1]^T$   | $> 0$             |                |
|           | $[-1, 0, 1]^T$  | $= 0$             | $[0, 1, 2]^T$  |
|           | $[-1, 1, -1]^T$ | $< 0$             |                |
|           | $[-1, 2, 1]^T$  | $> 0$             |                |
| 2         | $[1, 1, 1]^T$   | $> 0$             | $[-1, 2, 1]^T$ |
|           | $[1, 1, 2]^T$   | $> 0$             |                |
|           | $[1, 2, 1]^T$   | $> 0$             |                |
|           | $[-1, 0, 1]^T$  | $> 0$             | $[-1, 2, 1]^T$ |
|           | $[-1, 1, -1]^T$ | $> 0$             |                |
|           | $[-1, 2, 1]^T$  | $> 0$             |                |

表 1. 感知器算法求解过程。

感知器算法求出的判别函数为

$$g_1(\mathbf{x}) = 2x_1 + x_2 - 1 \quad (20)$$

分类线为

$$2x_1 + x_2 - 1 = 0 \quad (21)$$

(2) 求 MSE 分类器判别函数。

列出方程组

$$\mathbf{Y}\boldsymbol{\alpha} = \mathbf{b} \quad (22)$$

其中

$$\mathbf{Y} = \begin{bmatrix} \mathbf{y}_1^T \\ \vdots \\ \mathbf{y}_6^T \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 2 \\ 1 & 2 & 1 \\ -1 & 0 & 1 \\ -1 & 1 & -1 \\ -1 & 2 & 1 \end{bmatrix} \in \mathbb{R}^{6 \times 3} \quad (23)$$

$$\mathbf{b} = [1, 1, 1, 1, 1, 1]^T \quad (24)$$

求得

$$\boldsymbol{\alpha}^* = (\mathbf{Y}^T \mathbf{Y})^{-1} \mathbf{Y}^T \mathbf{b} = \begin{bmatrix} -0.2353 \\ 0.4902 \\ 0.3072 \end{bmatrix} \quad (25)$$

则 MSE 分类器的判别函数为

$$g_1(\mathbf{x}) = 0.4902x_1 + 0.3072x_2 - 0.2353 \quad (26)$$

#### 4. BP net. 10 分

为便于后续计算，令

$$\mathbf{W}^{(1)} = (\mathbf{W}^1)^T = \begin{bmatrix} -1.0 & 1.0 \\ -0.5 & 1.5 \\ 1.5 & -0.5 \end{bmatrix} \quad (27)$$

$$\mathbf{W}^{(2)} = (\mathbf{W}^2)^T = \begin{bmatrix} 1.0 & -2.0 & 0.5 \\ 0.5 & -1.0 & 1.0 \end{bmatrix} \quad (28)$$

则对这个三层模型，传播过程记为

$$\mathbf{a}^{(0)} = \mathbf{x} \quad (29)$$

$$\mathbf{z}^{(1)} = \mathbf{W}^{(1)} \mathbf{a}^{(0)}, \quad \mathbf{a}^{(1)} = \mathbf{z}^{(1)} \quad (30)$$

$$\mathbf{z}^{(2)} = \mathbf{W}^{(2)} \mathbf{a}^{(1)}, \quad \mathbf{a}^{(2)} = \mathbf{z}^{(2)} \quad (31)$$

其中

$$\mathbf{z}^{(1)} = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} \quad (32)$$

$$\mathbf{z}^{(2)} = \begin{bmatrix} -1.5 \\ 0 \end{bmatrix} \quad (33)$$

$$(34)$$

关于反向传播算法直接有

$$\frac{\partial \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})}{\partial \mathbf{W}^{(l)}} = \delta^{(l)} (\mathbf{a}^{(l-1)})^T \in \mathbb{R}^{M_l \times M_{l-1}} \quad (35)$$

其中  $M_l$  为第  $l$  层神经元的个数,  $\delta^{(l)}$  为第  $l$  层的误差项, 定义为

$$\begin{aligned} \delta^{(l)} &\triangleq \frac{\partial \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})}{\partial \mathbf{z}^{(l)}} \\ &= \frac{\partial \mathbf{a}^{(l)}}{\partial \mathbf{z}^{(l)}} \cdot \frac{\partial \mathbf{z}^{(l+1)}}{\partial \mathbf{a}^{(l)}} \cdot \frac{\partial \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})}{\partial \mathbf{z}^{(l+1)}} \\ &= 1 \cdot (\mathbf{W}^{(l+1)})^T \cdot \delta^{(l+1)} \\ &= (\mathbf{W}^{(l+1)})^T \delta^{(l+1)} \in \mathbb{R}^{M_l} \end{aligned} \quad (36)$$

则权重的更新方式为

$$\begin{aligned} \mathbf{W}^{(l)} &\leftarrow \mathbf{W}^{(l)} - \eta \cdot \frac{\partial \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})}{\partial \mathbf{W}^{(l)}} \\ &= \mathbf{W}^{(l)} - \eta \cdot \delta^{(l)} (\mathbf{a}^{(l-1)})^T \end{aligned} \quad (37)$$

注意到题中网络的输出为  $\mathbf{a}^{(2)} = \mathbf{z}^{(2)}$ , 这样对于输出层, 损失函数为

$$\mathcal{L} = \frac{1}{2} \|\mathbf{a}^{(2)} - \mathbf{y}\|_2^2 = \frac{1}{2} \|\mathbf{W}^{(2)} \mathbf{a}^{(1)} - \mathbf{y}\|_2^2 \quad (38)$$

则损失函数关于  $\mathbf{W}^{(2)}$  的梯度为

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(2)}} = (\mathbf{a}^{(2)} - \mathbf{y}) \cdot (\mathbf{a}^{(1)})^T \quad (39)$$

其中第二层误差项为

$$\delta^{(2)} = \mathbf{a}^{(2)} - \mathbf{y} = \begin{bmatrix} -2.5 \\ 1 \end{bmatrix} \quad (40)$$

求得

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(2)}} &= \delta^{(2)} \cdot (\mathbf{a}^{(1)})^T \\ &= \begin{bmatrix} -2.5 \\ 1 \end{bmatrix} \begin{bmatrix} 0 & 1 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 0 & -2.5 & -2.5 \\ 0 & 1 & 1 \end{bmatrix} \end{aligned} \quad (41)$$

第二层的权重更新为

$$\begin{aligned} \mathbf{W}^{(2)} &\leftarrow \mathbf{W}^{(2)} - 0.1 \cdot \frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(2)}} \\ &= \begin{bmatrix} 1.0 & -2.0 & 0.5 \\ 0.5 & -1.0 & 1.0 \end{bmatrix} - \begin{bmatrix} 0 & -0.25 & -0.25 \\ 0 & 0.1 & 0.1 \end{bmatrix} \\ &= \begin{bmatrix} 1.0 & -1.75 & 0.75 \\ 0.5 & -1.1 & 0.9 \end{bmatrix} \end{aligned} \quad (42)$$

同理可得第一层的误差项

$$\begin{aligned}
 \delta^{(1)} &= \left( \mathbf{W}^{(2)} \right)^T \delta^{(2)} \\
 &= \begin{bmatrix} 1.0 & 0.5 \\ -2.0 & -1.0 \\ 0.5 & 1.0 \end{bmatrix} \begin{bmatrix} -2.5 \\ 1 \end{bmatrix} \\
 &= \begin{bmatrix} -2 \\ 4 \\ -0.25 \end{bmatrix}
 \end{aligned} \tag{43}$$

则  $\mathbf{W}^{(1)}$  的梯度为

$$\begin{aligned}
 \frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(1)}} &= \delta^{(1)} \cdot (\mathbf{a}^{(0)})^T \\
 &= \begin{bmatrix} -2 \\ 4 \\ -0.25 \end{bmatrix} \begin{bmatrix} 1 & 1 \end{bmatrix} \\
 &= \begin{bmatrix} -2 & -2 \\ 4 & 4 \\ -0.25 & -0.25 \end{bmatrix}
 \end{aligned} \tag{44}$$

第一层的权重更新为

$$\begin{aligned}
 \mathbf{W}^{(1)} &\leftarrow \mathbf{W}^{(1)} - 0.1 \cdot \frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(1)}} \\
 &= \begin{bmatrix} -1.0 & 1.0 \\ -0.5 & 1.5 \\ 1.5 & -0.5 \end{bmatrix} - \begin{bmatrix} -0.2 & -0.2 \\ 0.4 & 0.4 \\ -0.025 & -0.025 \end{bmatrix} \\
 &= \begin{bmatrix} -0.8 & 1.2 \\ -0.9 & 1.1 \\ 1.525 & -0.475 \end{bmatrix}
 \end{aligned} \tag{45}$$

综上，该样本做一次修正后的权值为

$$\mathbf{W}^1 = \begin{bmatrix} -0.8 & -0.9 & 1.525 \\ 1.2 & 1.1 & -0.475 \end{bmatrix} \tag{46}$$

$$\mathbf{W}^2 = \begin{bmatrix} 1.0 & 0.5 \\ -1.75 & -1.1 \\ 0.75 & 0.9 \end{bmatrix} \tag{47}$$

## 5. Cost-sensitive L2-SVM. 10 分

Cost-sensitive L2-SVM 的原始问题为

$$\begin{aligned} \min \quad & \frac{1}{2} \mathbf{w}^T \mathbf{w} + \frac{1}{2} \sum_{i=1}^l C_i \xi_i^2 \\ \text{s.t.} \quad & y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, l \end{aligned} \quad (48)$$

写出原始问题的 Lagrange 函数为

$$L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + \frac{1}{2} \sum_{i=1}^l C_i \xi_i^2 - \sum_{i=1}^l \alpha_i [y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i] \quad (49)$$

原问题等价于 Lagrange 函数的极小极大问题，而对偶问题是 Lagrange 函数的极大极小问题，为了得到对偶问题的解，首先求  $L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha})$  对  $\mathbf{w}, b, \boldsymbol{\xi}$  的极小，由

$$\nabla_{\mathbf{w}} L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}) = \mathbf{w} - \sum_{i=1}^l \alpha_i y_i \mathbf{x}_i = 0 \quad (50)$$

$$\nabla_b L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}) = - \sum_{i=1}^l \alpha_i y_i = 0 \quad (51)$$

$$\nabla_{\xi_i} L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}) = C_i \xi_i - \alpha_i = 0 \quad (52)$$

得

$$\mathbf{w} = \sum_{i=1}^l \alpha_i y_i \mathbf{x}_i \quad (53)$$

$$\sum_{i=1}^l \alpha_i y_i = 0 \quad (54)$$

$$C_i \xi_i = \alpha_i \quad (55)$$

将式53 ~ 式55代入式49，得

$$\min_{\mathbf{w}, b, \boldsymbol{\xi}} L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}) = \sum_{i=1}^l \alpha_i - \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \frac{1}{2} \sum_{i=1}^l \frac{\alpha_i^2}{C_i} \quad (56)$$

再对  $\min_{\mathbf{w}, b, \boldsymbol{\xi}} L(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha})$  求  $\boldsymbol{\alpha}$  的极大，即得对偶问题：

$$\max_{\boldsymbol{\alpha}} \quad \sum_{i=1}^l \alpha_i - \frac{1}{2} \sum_{i=1}^l \frac{\alpha_i^2}{C_i} - \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \quad (57)$$

$$\text{s.t.} \quad \sum_{i=1}^l \alpha_i y_i = 0 \quad (58)$$

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, l \quad (59)$$

对上面的对偶最优化问题进行变换，进行必要的化简并将对目标函数求极大转换为求极小，可得 Cost-sensitive



L2-SVM 的对偶问题为

$$\min_{\alpha} \quad \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l \alpha_i \alpha_j y_i y_j \left( \mathbf{x}_i^T \mathbf{x}_j + \frac{\delta_{ij}}{C_i} \right) - \sum_{i=1}^l \alpha_i, \text{ where } \delta_{ij} = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases} \quad (60)$$

$$\text{s.t.} \quad \sum_{i=1}^l \alpha_i y_i = 0 \quad (61)$$

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, l \quad (62)$$

## 6. K-means. 10 分

已知

$$\begin{aligned} \mathbf{x}_1 &= [4, 5]^T, & \mathbf{x}_2 &= [1, 4]^T \\ \mathbf{x}_3 &= [0, 1]^T, & \mathbf{x}_4 &= [5, 0]^T \end{aligned}$$

$$(1) \quad C_1 = \{\mathbf{x}_1, \mathbf{x}_2\}, C_2 = \{\mathbf{x}_3, \mathbf{x}_4\}$$

两类的均值为

$$\mathbf{m}_1 = [2.5, 4.5]^T, \quad \mathbf{m}_2 = [2.5, 0.5]^T \quad (63)$$

误差平方和为

$$J_e^{(1)} = 18 \quad (64)$$

$$(2) \quad C_1 = \{\mathbf{x}_1, \mathbf{x}_4\}, C_2 = \{\mathbf{x}_2, \mathbf{x}_3\}$$

两类的均值为

$$\mathbf{m}_1 = [4.5, 2.5]^T, \quad \mathbf{m}_2 = [0.5, 2.5]^T \quad (65)$$

误差平方和为

$$J_e^{(2)} = 18 \quad (66)$$

$$(3) \quad C_1 = \{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3\}, C_2 = \{\mathbf{x}_4\}$$


两类的均值为

$$\mathbf{m}_1 = \left[ \frac{5}{3}, \frac{10}{3} \right]^T, \quad \mathbf{m}_2 = [5, 0]^T \quad (67)$$

误差平方和为

$$\begin{aligned} J_e^{(3)} &= \left\| \left[ 4 - \frac{5}{3}, 5 - \frac{10}{3} \right]^T \right\|^2 + \left\| \left[ 1 - \frac{5}{3}, 4 - \frac{10}{3} \right]^T \right\|^2 + \left\| \left[ 0 - \frac{5}{3}, 1 - \frac{10}{3} \right]^T \right\|^2 \\ &\approx 17.33 \end{aligned}$$

## 7. Bayes decision. 20 分



(1) 写出两个类的概率密度函数表达式。

两类的类条件概率密度为

$$p(x|\omega_1) = \begin{cases} 0.25x, & 0 \leq x < 2 \\ -0.25x + 1, & 2 \leq x < 4 \end{cases} \quad (68)$$

$$p(x|\omega_2) = \begin{cases} 0.25x - 0.75, & 3 \leq x < 4 \\ 0.25, & 4 \leq x < 7 \\ -0.25x + 2, & 7 \leq x < 8 \end{cases} \quad (69)$$

(2) 求最小错误率 Bayes 决策的决策边界。

令

$$\frac{p(x|\omega_1)}{p(x|\omega_2)} = \frac{P(\omega_2)}{P(\omega_1)} \quad (70)$$

解得决策边界为

$$x_{threshold}^{(1)} = \frac{17}{5} = 3.4 \quad (71)$$

(3) 求最小风险 Bayes 决策的决策边界。

令

$$\frac{p(x|\omega_1)}{p(x|\omega_2)} = \frac{P(\omega_2)}{P(\omega_1)} \cdot \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}} \quad (72)$$

解得决策边界为

$$x_{threshold}^{(2)} = \frac{25}{7} \approx 3.57 \quad (73)$$

## 8. 简答题. 10 分

略。